



AI PM Bench | PRD

1. 背景与机会

- **产品形态**：轻量级Web工具
- **目标用户**：AI 产品经理（B端角色，C端使用方式）
- **主要场景**：在需求确定与开发启动之间，帮助 AI PM 快速完成模型选型与 Prompt 验证。
- **核心痛点**：无法快速、低成本地验证哪个模型更好和这个 Prompt 写得好不好。
- **市场机会**：大模型选型爆发，PM选型成本急剧上升，Prompt工程成为了AI PM必备技能，但缺乏标准化工具。

2. 目标

2.1 业务目标

帮助AI PM在需求确定后、开发启动前，快速完成模型选型与Prompt验证，将决策从2-4小时缩短至10分钟以内，同时控制单次评测成本。

2.2 用户体验目标

目标	定义	目标值	对应痛点
操作简洁	从打开工具到开始评测的点击/输入次数	≤ 5 步	手动对比效率低
快速响应	从点击开始到报告展示的耗时	≤ 60 秒	等待焦虑
结果可用	报告无需二次加工，可直接复制到 PRD	用户确认	报告不可用

2.3 产品功能目标

目标	定义	目标值	对应痛点
双场景覆盖	支持模型选型 + Prompt 优化	2 个场景	工具覆盖不全
模型覆盖	支持的模型数量	≥ 3 种	选型对比范围窄
自动化程度	用户无需手动准备测试用例和 prompt	100% 自动生成	手动准备耗时

2.4 质量与成本目标

目标	定义	目标值	对应痛点
评测成功率	无错误完成评测的比例	≥ 95%	工具不可靠
推荐准确率	用户认可推荐的比例（后续验证/反馈）	≥ 80%	推荐不可信
单次评测成本	每次评测的 API 调用费用	≤ ¥0.6	运营成本失控

2.5 使用与留存目标

目标	定义	目标值
任务完成率	开始评测 → 成功看到报告的比例	≥ 90%
周留存率	一周内再次使用的用户比例	≥ 40%
报告复制率	用户点击「复制报告」的比例	≥ 70%

2.6 Go / No-Go（MVP 发布）标准

- **Go（可发布）**：评测耗时 ≤ 60 秒 + 评测成功率 ≥ 95% + 用户可独立完成 ≤ 5 步 + 报告复制率 ≥ 70%，单次评测实际成本 ≤ ¥0.7。
- **No-Go（不可发布）**：任一关键指标未达标，或出现高频致命错误（无法完成评测/无法生成报告/页面不可用），成本 > ¥0.9 且无优化方案。

3. 范围

3.1 首版（MVP）必须包含

场景一：模型选型

功能	优先级	说明
输入场景描述	P0	核心入口
AI 自动生成测试用例（5条）	P0	核心价值
勾选多个对比模型	P0	覆盖主流
批量调用模型 API	P0	核心功能
生成分析报告（推荐 + 对比表）	P0	核心输出

场景二：Prompt 优化

功能	优先级	说明
输入场景 + 生成/优化 Prompt	P1	v1.1（MVP 不做；或 MVP 仅保留“生成初始 Prompt”）
对比多个 Prompt 版本	P1	v1.1（MVP 不做）

基础能力

功能	优先级	说明
API Key 配置（前端存储）	P0	后端统一Key
进度反馈（步骤 + 预计时间）	P0	体验必需
报告复制/下载	P0	输出可用
历史任务保存	P1	复用价值

3.2 不在本期（Out of scope）

- 用户登录/账号系统
- 本地模型/Git 模型接入
- 数据看板
- 成本异常告警
- 团队协作
- 付费/订阅功能

4. 用户画像与核心需求

4.1 目标用户

- AI 产品经理
 - 典型使用频率：每周 2-5 次（需求评审后、立项前、方案评估阶段）
 - 技术能力分层：
 - 基础：会写Prompt、会用常见AI工具；对token/temperature等概念有基础认知
 - 进阶：理解token/temperature/top_p等参数；可读懂简单JSON；可能会写少量脚本做数据整理
 - 痛点优先级（可配置）：时间成本（首要） / 评测成本 / 结果可信度（准确率 & 可解释性）

4.2 用户需求

- 用户需要明确知道什么模型最适配于负责项目。
- 用户对prompt的编写与优化。

5. 用户旅程与流程（MVP）

AIPM Bench 是一个帮助 AI PM 完成「模型选型」和「Prompt 设计优化」的智能工作台。用户只需描述场景，系统自动生成测试用例、批量评测、输出分析报告—既支持对比不同模型，也支持对比同一模型下的不同 prompt 版本。

场景一：模型选型

- 1. 打开工具 AIPM Bench
 - 选择模型选型评测模式
- 2. 进行需求对话
 - 输入场景描述
 - 输入自定义的Prompt，或是AI工具依据场景描述自动生成Prompt
- 3. 模型选取
 - 勾选需要对比的模型
- 4. 开始测试
 - 系统自动生成测试用例、批量评测、输出报告
 - 选出最合适的模型

场景二：Prompt生成与优化

- 1. 打开工具 AIPM Bench
 - 选择Prompt生成与优化模式
- 2. 进行需求对话
 - 输入场景描述
 - 直接让系统生成Prompt，或者是输入Prompt让系统优化
- 3. 模型选取
 - 勾选一个需要测试的模型
- 4. 开始测试
 - 系统自动生成测试用例、批量评测、输出报告
 - 选出最合适的Prompt

6. 功能需求

6.1 场景一：模型选型

- FR-1：场景描述输入

项目	内容
功能描述	用户输入自然语言描述，说明需要模型完成的任务和输出要求
输入方式	多行文本输入框
必填	是
示例	自动提取会议纪要中的待办事项，输出 JSON 格式，包含 task、owner、deadline
边界条件	输入为空时提示“”“请描述你的场景”“”；超过 500 字时提示“”“建议精简描述”“”
验收标准	用户可输入并提交场景描述；支持复制粘贴

- FR-2：AI 自动生成测试用例

项目	内容
功能描述	系统根据用户输入的场景描述，自动生成 5 条代表性测试用例
生成方式	调用分析模型（如 GPT-4o）生成
输出格式	列表形式，每条用例为一段自然语言文本
用例覆盖	正常场景（3 条）+ 边界场景（1 条）+ 异常场景（1 条）
验收标准	生成用例与场景描述相关；用户可查看、可编辑修改

• FR-3: 模型选择

项目	内容
功能描述	用户勾选需要对比评测的模型
可选模型	GPT-4o、Claude 3.5 Sonnet、GPT-3.5 Turbo (MVP 阶段)
选择方式	多选框，支持全选/取消
最少选择	至少勾选 2 个模型，否则提示““请至少选择 2 个模型进行对比””
验收标准	用户可勾选/取消模型；未选够 2 个时无法开始评测

• FR-4: API Key 配置

项目	内容
功能描述	用户为每个选中的模型配置对应的 API Key，系统使用预设的API Key（开发者统一申请），用户无需配置
存储方式	前端 Session 存储，后端环境变量存储
交互方式	每个模型独立输入框，不展示API Key相关UI
校验	点击开始评测时，校验 Key 格式；后端启动时校验一次，失败则提示维护
验收标准	用户打开工具即可直接使用，无需任何Key配置

• FR-5: 批量评测执行

项目	内容
功能描述	系统自动调用各模型 API，用每条测试用例进行评测
执行方式	顺序执行（模型 → 用例），避免限流
超时设置	单次调用超时 30 秒，超时标记为失败
重试机制	失败自动重试 1 次
进度反馈	实时显示当前执行的模型和用例进度
验收标准	所有选中模型完成所有用例评测；超时/失败有明确标记

• FR-6: 分析报告生成

项目	内容
功能描述	系统根据评测结果，自动生成分析报告
生成方式	调用分析模型综合分析
报告内容	- 推荐模型及理由 - 各模型对比表（成功率、耗时） - 各模型优缺点分析 - 成本预估（静态价格表） - 最终建议
输出格式	Markdown 格式
验收标准	报告内容完整；用户可阅读、可复制

• FR-7: 结果输出操作

项目	内容
功能描述	用户可复制或下载评测结果
支持操作	- 一键复制报告（Markdown） - 下载原始数据（JSON）
验收标准	复制功能成功复制到剪贴板；下载功能生成 JSON 文件

• FR-8: 后端代理调用

项目	内容
功能描述	前端不直接调用模型API，而是调用自己的后端服务
后端路径	POST /api/evaluate
请求体	{ scene_description, models: ["gpt-4o", "claude-3.5-sonnet"], test_cases: [...] }

响应体	{ results: { model_name: { case_results, success_rate, total_duration_ms } }, report: "markdown" }
超时设置	后端单次模型调用30秒超时，整体评测60秒超时
验收标准	所有模型API调用走后端代理，前端不接触任何API Key

6.2 场景二：Prompt 优化（v1.1，MVP 不实现）

- FR-9：Prompt生成与优化

项目	内容
功能描述	用户输入场景描述，系统自动生成初始 Prompt；或用户输入已有 Prompt，系统提供优化建议
输入方式	场景描述（必填）+ 已有 Prompt（选填）
输出	2-3 个 Prompt 版本（基础版、结构化版、带示例版）
验收标准	生成的 Prompt 与场景相关；格式清晰可用

- FR-10：Prompt版本对比

项目	内容
功能描述	用户选择固定模型，系统对多个 Prompt 版本进行批量评测对比
对比方式	同一模型 + 同一测试用例集 + 不同 Prompt 版本
输出	对比表 + 各版本成功率 + 推荐版本
验收标准	用户可看到哪个 Prompt 版本表现最好

6.3 基础能力

- FR-11：进度反馈

项目	内容
功能描述	评测执行过程中，实时展示进度状态
展示内容	- 整体进度条 - 当前步骤（生成用例/评测模型A/评测模型B/生成报告） - 当前模型已完成的用例数 - 预计剩余时间
验收标准	用户能清晰了解当前进度；无进度卡死无反馈

- FR-12：历史任务保存

项目	内容
功能描述	评测完成后自动保存任务配置和结果
保存内容	场景描述、选中的模型、测试用例、评测结果、报告
存储方式	浏览器 localStorage
历史列表	展示任务名称、时间、推荐模型
操作	点击历史任务可加载配置，支持重新评测
验收标准	刷新页面后历史任务可查看；可加载复用

- FR-13：错误处理

项目	内容
功能描述	系统对各类异常情况进行友好提示和处理
异常类型	- API Key 无效：提示并跳过该模型 - 单次调用超时：标记失败，继续执行 - 所有模型失败：提示""评测失败，请检查配置"" - 分析模型失败：展示原始数据，提示""报告生成失败，以下是原始结果""
验收标准	各类异常有明确提示；系统不崩溃；用户知道下一步该做什么

当所有模型失败时，显示「重新评测」按钮，保留当前配置（不清空 API Key 和场景描述）

7. 非功能需求

- 7.1 性能需求

编号	需求描述	目标值	测量方式
NFR-P1	单次完整评测（3 模型 × 5 用例）的总耗时	≤ 60 秒	端到端计时（点击开始 → 报告展示）
NFR-P2	单次模型 API 调用超时阈值	30 秒	超时则标记失败，不阻塞整体
NFR-P3	报告生成（分析模型调用）耗时	≤ 10 秒	从评测完成到报告展示
NFR-P4	页面首次加载时间	≤ 3 秒	浏览器 DevTools 测量

- 7.2 可靠性需求

编号	需求描述	目标值	测量方式
NFR-P1	评测整体成功率	≥ 95 %	成功次数 / 总评测次数
NFR-P2	单次调用失败自动重试次数	1 次	失败后自动重试，仍失败则标记
NFR-P3	部分模型失败时的降级策略	继续评测其他模型	一个模型失败不影响其他
NFR-P4	分析模型失败时的降级策略	展示原始评测数据	用户仍能看到原始对比结果
NFR-P5	系统无单点崩溃	任一组件的失败不影响整体页面可用	异常捕获 + 友好提示

- 7.3 安全需求

编号	需求描述	实现方式
NFR-P1	API Key 不经过服务器	仅存储在前端 Session / LocalStorage，不上传到任何后端
NFR-P2	API Key 输入掩码	输入框类型为 password，不可见明文
NFR-P3	无用户数据持久化到服务器	所有用户数据（场景、用例、结果）仅存本地
NFR-P4	第三方 API 调用最小权限	仅调用必需的模型 API，不做额外数据上报
NFR-P5	防止恶意调用	前端LocalStorage记录每日评测次数（最多20次）+ 10秒内防重复点击

- 7.4 可用性需求

编号	需求描述	目标值	测量方式
NFR-P1	用户完成一次评测的操作步骤	≤ 5 步	从打开工具到点击「开始评测」的点击/输入次数
NFR-P2	核心功能（输入场景、选模型、开始）在一屏内可见	无需滚动即可看到主要操作	视觉检查
NFR-P3	错误提示清晰可操作	用户知道「哪里错了 + 怎么办」	用户测试反馈
NFR-P4	进度反馈实时可见	评测过程中用户始终知道当前状态	视觉检查
NFR-P5	报告可读性	无需二次加工可直接复制到 PRD	用户确认

- 7.5 兼容性需求

编号	需求描述	实现方式
NFR-P1	浏览器兼容	Chrome（最新 2 个版本）、Edge（最新 2 个版本）
NFR-P2	设备兼容	桌面端 Web（1920×1080、1366×768、1440×900）
NFR-P3	响应式布局	窗口宽度变化时，布局自适应不溢出

- 7.6 可维护性需求

编号	需求描述	实现方式
NFR-P1	模型配置可扩展	新增模型时，只需在配置文件中添加，无需改核心代码
NFR-P2	分析报告模板可配置	报告格式可独立修改，不依赖代码逻辑
NFR-P3	代码结构清晰	模型调用层、分析层、展示层分离

- 7.7 成本需求

编号	需求描述	目标值	说明
NFR-P1	单次评测 API 成本	≤ ¥0.6	包含：测试用例生成（1 次调用）+ 模型评测（3 模型 × 5 用例 × 调用费）+ 报告生成（1 次调用）

NFR-P2	分析模型成本占比	≤ 30%	测试用例生成 + 报告生成 / 总成本
NFR-P3	MVP 阶段月运营成本	≤ ¥ 300	假设 500 次评测/月，单次 ¥ 0.6

- 7.8 调用限额与防滥用

编号	需求描述
前端限流	同一会话内限制连续点击触发频率（例如 10 秒内仅允许发起 1 次评测请求），避免误触/脚本高频调用
每日限额（Session 维度）	同一浏览器会话每日最多 20 次评测 （前端计数 + LocalStorage 记录），超出后提示次日使用
降级策略	达到限额时仍允许查看历史结果，但禁止发起新评测

8. 口径与埋点

8.1 指标口径

- 指标1：评测耗时

项目	内容
指标定义	从用户点击「开始评测」到「报告展示完成」的总耗时
统计范围	全部评测任务
计量单位	秒（s）
计算公式	报告展示完成时间戳 — 开始评测点击时间戳
剔除场景	用户中途取消、网络断开导致失败的评测
目标值	≤ 60 秒（MVP）

- 指标2：评测成功率

项目	内容
指标定义	成功完成评测的比例
成功标准	至少 1 个模型完成全部用例评测 + 报告成功生成
统计范围	全部发起的评测任务
计算公式	成功评测次数 / 总评测发起次数
剔除场景	无（失败也需要统计）
目标值	≥ 95%（MVP）

- 指标3：推荐准确率

项目	内容
指标定义	系统推荐的模型被用户采纳的比例
采纳标准	用户最终使用系统推荐的模型进行后续开发（需后续验证，或用「复制报告」作为代理指标）
统计范围	完成评测的任务
计算公式	用户采纳推荐次数 / 完成评测次数
目标值	≥ 80%

- 指标4：单次评测成本

项目	内容
指标定义	完成一次评测产生的 API 调用总费用
统计范围	全部成功完成的评测
费用构成	测试用例生成（1 次调用）+ 模型评测（M 个模型 × N 条用例 × 单价）+ 报告生成（1 次调用）
计算公式	各模型 API 调用费用 + 分析模型调用费用
目标值	≤ ¥ 0.6（MVP）

- 指标5：用户操作步骤

项目	内容
指标定义	用户完成一次完整评测所需的核心操作次数
操作定义	输入/选择/点击等主动操作，不包括滚动、悬停
统计方式	定性定义 + 埋点验证
计算公式	各步骤操作次数的累加
目标值	≤ 5 步

8.2 埋点列表

• 页面访问埋点

埋点ID	事件名称	触发时机	上报字段
PV-01	page_view	页面加载完成	page_url, referrer, timestamp

• 功能交互埋点

埋点ID	事件名称	触发时机	上报字段
CLK-01	btn_start_eval_click	点击「开始评测」按钮	model_count, test_case_count, timestamp
CLK-02	btn_copy_report_click	点击「复制报告」按钮	report_length, timestamp
CLK-03	recommendation_feedback	用户对「推荐是否有用」反馈	task_id, useful (true/false), timestamp
CLK-04	btn_download_json_click	点击「下载 JSON」按钮	timestamp
CLK-05	select_model	勾选/取消模型	model_name, action (add/remove)
CLK-06	input_api_key	输入 API Key	model_name (不记录 Key 内容)
CLK-07	load_history_task	加载历史任务	task_id, timestamp

• 评测流程埋点

埋点ID	事件名称	触发时机	上报字段
EVAL-01	eval_start	评测流程开始	task_id, model_list, test_case_count, timestamp
EVAL-02	eval_model_start	单个模型开始评测	task_id, model_name
EVAL-03	eval_model_case_result	单条用例评测完成	task_id, model_name, case_index, success (true/false), duration_ms, 选)
EVAL-04	eval_model_complete	单个模型评测完成	task_id, model_name, success_rate, total_duration_ms
EVAL-05	eval_complete	全流程评测完成	task_id, duration_ms, success, total_cost
EVAL-06	eval_fail	评测失败	task_id, fail_reason, failed_model, timestamp

• 报告生成埋点

埋点ID	事件名称	触发时机	上报字段
RPT-01	report_generate_start	开始生成报告	task_id
RPT-02	report_generate_complete	报告生成完成	task_id, duration_ms, success
RPT-03	report_view	用户展开/查看报告	task_id, scroll_depth (可选)

8.3 埋点字段说明

字段名	类型	说明
task_id	String	本次评测的唯一标识
model_name	String	模型名称
success	Boolean	是否成功
duration_ms	Integer	耗时（毫秒）
timestamp	Integer	事件发生时间戳（毫秒）

fail_reason	String	失败原因
model_count	Integer	勾选的模型数量
test_case_count	Integer	测试用例数量

8.4 埋点采集方式

项目	内容
采集方式	前端自动上报
上报协议	HTTP POST（JSON 格式）
上报地址	/api/collect（MVP 阶段可先打印到控制台，或使用第三方分析工具）
采样率	100%（全部用户）
本地存储	埋点失败时存入 LocalStorage，下次页面加载时重试上报
隐私保护	不上报 API Key、不上报完整测试用例内容（仅上报用例数量）

9. 里程碑（Milestones）

阶段	时间	核心目标	交付物
M1：需求确认	第 1 周	完成需求定义与设计	PRD 文档、功能清单、高保真原型
M2：技术验证	第 2 周	验证核心技术可行性	API 调用 Demo、报告生成 Demo
M3：MVP 开发	第 3-4 周	完成 PO 功能开发	可运行的 MVP 版本
M4：内测与修复	第 5 周	内部验证 + Bug 修复	内测报告、问题修复清单
M5：MVP 发布	第 6 周	对外发布	公开访问链接 + 使用文档

10. 风险与对策（Risks）

10.1 技术风险

编号	风险描述	概率	影响	应对措施
R-T01	模型 API 限流或不可用	中	高	1. 实现自动重试机制 2. 失败时跳过该模型，继续其他 3. 提示用户稍后重试
R-T02	单次评测耗时过长（> 60 秒）	中	中	1. 优化调用顺序（并行 vs 串行权衡） 2. 减少默认测试用例数（5 → 3） 3. 添加超时提示和取消按钮
R-T03	分析模型生成报告格式不稳定	中	中	1. 使用结构化输出（JSON mode） 2. 后端做格式校验和兜底 3. 报告模板硬编码 + 变量填充
R-T04	本地存储容量限制（历史任务）	低	低	限制历史任务数量（最多 20 条），超出时自动删除最早的

10.2 成本风险

编号	风险描述	概率	影响	应对措施
R-C01	单次评测成本超预期	中	中	1. 监控每次评测的 API 调用量 2. 限制测试用例数量（最多 5 条） 3. 使用更便宜的分析模型（GPT-3.5）
R-C02	MVP 阶段运营成本失控	低	中	1. 执行第7.8节的防滥用策略（前端限流+每日20次限额） 2. 用户自己承担成本，每日限额20次，单用户限流，上线后监控每日成本告警

10.3 进度风险

编号	风险描述	概率	影响	应对措施
R-S01	开发进度延期	中	中	1. MVP 功能砍到最小（仅模型选型） 2. Prompt 优化场景明确为 P1 3. 每周进度同步，及时调整
R-S02	需求变更	中	低	1. MVP 范围冻结后不接受新需求 2. 新需求放入「后期规划」

10.4 安全与合规风险

编号	风险描述	概率	影响	应对措施
R-SEC01	API Key 泄露	低	高	1. 仅存储在前端 Session 2. 不上传任何服务器 3. 输入框掩码 + 明确提示
R-SEC02	用户输入敏感数据	中	中	1. 明确提示「不上传服务器」 2. 不上报完整测试用例内容 3. 建议用户脱敏

10.5 用户采纳风险

编号	风险描述	概率	影响	应对措施
R-U01	用户觉得操作复杂	中	中	1. 提供示例模板（一键填充） 2. 添加 onboarding 引导 3. 录屏演示完整流程
R-U02	推荐模型不被信任	中	中	1. 报告展示原始对比数据 2. 用户可查看每条用例的输出 3. 提供「重新评测」按钮

10.6 应急预案

场景	应急措施	负责人
评测大面积失败	降级为「仅展示原始数据」，不依赖分析模型	开发
API 成本超预算	临时限制每日评测次数，通知用户	PM
用户反馈强烈不满	快速迭代修复，发布 hotfix	开发 + PM
安全事件（Key 泄露）	立即下线，通知用户更换 Key，修复后重新上线	开发 + 安全